PROMPT: Padronização de bancos de dados imunogenéticos

Daniella Alves Silva, Ana Carolina Figueiredo Modesto, Keila Correia de Alcântara

ARQUIVO DE ENTRADA:

- **Formato:** Excel .xlsx
- **Colunas principais:**
  - Identificação do paciente
  - Data de nascimento e de coleta
  - Sexo
  - Cidade e estado de residência
  - Resultado RT-qPCR para covid-19
  - Colunas HLA (28 no total)
  - Outras colunas auxiliares

ETAPAS:

- Leitura do arquivo e renomeação das colunas
- Exclusão de registros incompletos ou inválidos
- Cálculo da idade
- Padronização das variáveis categóricas
- Limpeza e padronização das colunas HLA
- Tratamento de duplicatas
- Exportação do banco final

COLUNAS HLA: A1, A2, B1, B2, C1, C2, DQA11, DQA12, DQB11, DQB12, DPA11, DPA12, DPB11, DPB12, DRB11, DRB12, DRB31, DRB32, DRB41, DRB42, DRB51, DRB52

FERRAMENTAS E ESTRATÉGIAS RECOMENDADAS

- pandas – para leitura, manipulação e limpeza dos dados
- numpy – para tratamento de nulos, idade
- re – para aplicar expressões regulares nas colunas HLA

- openpyxl – para exportar com controle total sobre o tipo de célula
- salvar como .xlsx seguro para Excel
- Solicitar retorno para visualização prévia das aplicações:
- Retornar quantas observações foram corrigidas ou excluídas
- Mostrar exemplos de correções ou exclusões realizadas, exibindo: valor original, valor corrigido, linha e coluna.
- Retornar o total de linhas do banco antes e após a limpeza.

EXEMPLOS DE PADRÕES VÁLIDOS

- Numéricos com: 01:01, 02:10:01, 105:01:01
- Numéricos com letras: 02:01P, 04:01:01G, 27:05P
- Números seguidos de letras após :01:ABUNB, 13:AEEPF, 01:NOVO
- Células vazia, a depender do caso

ETAPAS DETALHADAS

1. **Upload manual e leitura do banco de dados**
   - Upload manual do arquivo Excel (.xlsx) no Google Colab
   - Garante que as colunas sejam lidas como texto (string)
   - Captura o nome do arquivo automaticamente.
   - Apresenta informações iniciais do banco de dados para inspeção: quantidade de linhas, colunas e nome das variáveis
   - Importa as bibliotecas pandas (para análise de dados) e files (para upload no Colab).
   - Exibe as primeiras 5 linhas para inspeção visual.

2. **Renomeação das colunas e exclusão de colunas desnecessárias**
   - **Objetivo:** Carregar os dados corretamente e padronizar os nomes das colunas essenciais para análise.
   - **Renomear as colunas conforme a tabela abaixo**:

Coluna original	Nome padronizado
CODIGO_PEDIDO	Código do paciente
DTCOLETA_PEDIDO	Data da coleta
NASCIMENTO_PACEXTERNO	Data de nascimento
SEXO_PACEXTERNO	Sexo
NOME_CIDADE	Cidade
SIGLA_UF	Estado
RESULTADO	Resultado covid-19
A1_RESHLA	A1
A2_RESHLA	A2
B1_RESHLA	B1
B2_RESHLA	B2
C1_RESHLA	C1
C2_RESHLA	C2
DQA11_RESHLA	DQA11
DQA12_RESHLA	DQA12
DQB11_RESHLA	DQB11
DQB12_RESHLA	DQB12
DPA11_RESHLA	DPA11
DPA12_RESHLA	DPA12
DPB11_RESHLA	DPB11
DPB12_RESHLA	DPB12
DRB11_RESHLA	DRB11
DRB12_RESHLA	DRB12
DRB31_RESHLA	DRB31
DRB32_RESHLA	DRB32
DRB41_RESHLA	DRB41
DRB42_RESHLA	DRB42
DRB51_RESHLA	DRB51
DRB52_RESHLA	DRB52

- **Excluir as colunas completamente:** CT_I, CT_N, CT_ORF1AB, QTDE_HLA, QTDE_HLA_EXTERNO

3. **Inspeção de “-”, “Não Testado” e variações**
    - Identificar todos os valores que contenham hífen e “Não Testado”

4. **Limpeza de registros com valores “-”, “Não Testado” e variações**
    - Objetivo: Substituir por célula vazia ("") somente o conteúdo que representa ausência de informação nas colunas HLA, preservando os demais valores exatamente como estão no banco original.
    - Regras de substituição para "", se o valor for:
        - Qualquer variação de escrita de “Não testado”, com ou sem acento, em maiúsculas ou minúsculas, com possíveis codificações corrompidas. Exemplos válidos para substituição: "Nao Testado", "NÃO TESTADO", "nÃ£o testado", "nÃƒO TESTADO", "nãO testado", etc.
        - A string "-" (hífen isolado)
        - A string que começa com qualquer variação de “não testado” seguida por dois-pontos (como "Não Testado:-", "nÃo testado:-" etc.)
    - **Importante:**
        - As linhas não devem ser excluídas
        - O conteúdo restante não deve ser convertido em minúsculas
        - Apenas as células com os padrões mencionados devem ser substituídas por "" (vazio)

5. **Padronização da variável categórica sexo**
    - Padronizar:
        - Feminino e Masculino
        - Excluir linha com valor inválido ou se sexo estiver vazio

6. **Exclusão de linhas com valores ausentes em data de nascimento e/ou data da coleta**
    - Objetivo: Eliminar linhas com ausência de informações básicas obrigatórias ou inconsistências críticas.
    - Excluir se todas as 28 colunas HLA estiverem vazias, nulas ou com string vazia.
    - A filtragem será feita com base na verificação por linha:
        - Se todas as colunas HLA estiverem vazias → excluir a linha
        - Se pelo menos uma das colunas HLA tiver conteúdo → manter
    - Excluir linhas se for verificado pelo menos uma das seguintes condições:
        - Data de nascimento estiver vazia
        - Data da coleta estiver vazia

7. **Inspeção se há linhas com valores ausentes em data de nascimento e/ou data da coleta**
    - Verificar se todas as linhas com valores ausentes nas colunas data de nascimento e data da coleta foram excluídas

8. **Exclusão de linhas com valores ausentes em sexo e/ou cidade**
    - Excluir linhas se for verificado pelo menos uma das seguintes condições:
        - Sexo estiver vazio
        - Cidade estiver vazio

9. **Inspeção se há linhas com valores ausentes em sexo e/ou cidade**
    - Verificar se todas as linhas com valores ausentes nas colunas sexo e cidade foram excluídas

10. **Exclusão de linhas com valores ausentes ou inválidos em resultado covid-19**
    - Excluir linhas se o resultado for “inconclusivo” (qualquer variação de maiúsculas/minúsculas) ou estiver vazio
    - Tanto resultados positivos quanto negativos serão mantidos para a análise.

11. Inspeção se há linhas com valores ausentes ou inválidos em resultado covid-19

- Verificar se todas as linhas com valores ausentes na coluna resultado covid-19 foram excluídas

12. Exclusão de linhas com todas as colunas HLA vazias

- Excluir somente as linhas em que todas as colunas HLA estejam vazias ao mesmo tempo.

13. Inspeção se há linhas com todas as colunas HLA vazias

- Verificar se todas as linhas com todos os valores ausentes nas colunas HLA foram excluídas

14. Inspeção dos valores únicos da variável covid-19

- Exibir a lista de valores únicos existentes na coluna, e a frequência absoluta de cada valor

15. Padronização da variável covid-19

- Corrigir e padronizar a nomenclatura dos valores:
    - ❖ “"nã£o detectado (ausãªncia do rna de coronavãrus sars-cov-2)" -> “Não detectado”
    - ❖ detectado (presenã§a do rna de coronavã-rus sars-cov-2 -> “Detectado”

16. Filtro para resultados detectados e não detectados em resultado covid-19

- Manter na planilha somente linhas com resultados detectados e não detectados em resultado covid-19
- Exibir a frequência absoluta e relativa de cada valor

17. Inspeção e criação de vetor das colunas HLA

- Identificar quais são as colunas HLA, sendo elas:

- 'A1', 'A2', 'B1', 'B2', 'C1', 'C2', 'DQA11', 'DQA12', 'DQB11', 'DQB12', 'DPA11', 'DPA12', 'DPB11', 'DPB12', 'DRB11', 'DRB12', 'DRB31', 'DRB32', 'DRB41', 'DRB42', 'DRB51', 'DRB52'

18. Remoção de linhas com números inteiros nas colunas HLA

- Excluir linha se qualquer coluna HLA contiver: apenas números inteiros, sem símbolos
- Ex: 10, 1501, 7

19. Inspeção se há linhas com números inteiros

- Verificar se todas as linhas com números inteiros nas colunas HLA foram excluídas

20. Remoção de linhas com números decimais nas colunas HLA

- Excluir linha se qualquer coluna HLA contiver: número decimal (com vírgula ou ponto)
- Ex: 0.125, 0,41736

21. Inspeção se há linhas com números decimais

- Verificar se todas as linhas com números decimais nas colunas HLA foram excluídas

22. Remoção de linhas com valores contendo "/" nas colunas HLA

- Excluir linha se qualquer coluna HLA contiver: qualquer valor contendo barra /
- Ex: 02:02/06, 0301/2832

23. Inspeção se há linhas com "/"

- Verificar se todas as linhas com "/" nas colunas HLA foram excluídas

24. Remoção de linhas com apenas letras nas colunas HLA

- Excluir linha se qualquer coluna HLA contiver: apenas letras
- Ex: CGDV, XYZ
- Critério de exclusão de linha:
    - ❖ Excluir uma linha se pelo menos uma das colunas HLA contiver um valor que seja composto somente por letras do alfabeto (A-Z).
    - ❖ Isso inclui tanto letras maiúsculas quanto minúsculas.
    - ❖ A exclusão deve ocorrer mesmo que apenas uma das colunas HLA da linha contenha esse tipo de valor.
- Critério para manter a linha:
    - ❖ Manter todas as linhas em que nenhuma coluna HLA contenha apenas letras.
    - ❖ Valores contendo números, caracteres especiais (como *, :, -, etc.) ou valores vazios/nulos não devem levar à exclusão da linha.

25. Inspeção se há linhas com apenas letras

- Verificar se todas as linhas com apenas letras nas colunas HLA foram excluídas

26. Correção de valores com "*" e letras a esquerda nas colunas HLA

- Remover o * e tudo antes dele (prefixo):
    - ❖ B*35:DGBGX → 35:DGBGX
    - ❖ DRB1*14:DGBHB → 14:DGBHB

27. Inspeção se há valores com "*" e letras a esquerda

- Verificar se todos os valores foram corrigidos, mediante exclusão do asterisco e prefixo nas colunas HLA

28. Correção de valores colados sem ":"

- Inserir dois pontos entre número e letras:
    - ❖ 03FKYB → 03:FKYB

29. Inspeção se há valores sem “:”

- Verificar se todos os valores colados foram corrigidos, mediante inclusão de dois pontos (:) entre números e letras nas colunas HLA

30. Exclusão de linhas com o erro “day”

- Remover linhas em que qualquer coluna HLA contenha a palavra “day” seguida de uma vírgula (característico de erro de conversão de data/hora)

31. Inspeção se há linhas com o erro “day”

- Verificar se todas as linhas com erro “day” nas colunas HLA foram excluídas

32. Inspeção de valores terminados com “:00” nas colunas HLA

- Objetivo: Verificar se existem observações, nas colunas HLA, cujo último campo (após os dois-pontos) seja igual a "00".
- **Formato da observação:**
  - As observações HLA podem conter blocos separados por dois-pontos (:), como 07, 07:02, 07:02:01, 07:02:00.
  - O que define se a observação será contabilizada é somente o último bloco.
  - O último bloco deve ser exatamente "00" para a observação ser considerada.
- **Exemplo de contagens**
  - 07:02:00 ⬛ (último campo = 00)
  - 14:00 ⬛ (último campo = 00)
  - 07:00:02 + (último campo = 02, não 00)
  - 14:02 + (último campo = 02)
- **Tratamento de valores ausentes ou formatos diferentes**
  - Células vazias ou NaN devem ser ignoradas (não contam).
  - Espaços extras devem ser removidos antes da verificação.

➢ **CÓDIGO ESPECIAL**: preservar no banco somente linhas com final ":00" para conferência de amostras no R

33. Exclusão de ":00" no final de valores das colunas HLA

- Durante a exportação do Excel e a leitura da planilha no Python, algumas observações nas colunas HLA foram convertidas para formato de hora. Por exemplo:
  - 07:02:00 → deveria ser 07:02
  - 15:30:00→deveria ser 15:30

- Ação: Corrigir os valores apenas nas colunas HLA, removendo o :00 do final, quando existir.
- Não alterar nenhuma outra coluna que não seja de HLA.
- Exemplo de transformação esperada:
  - Entrada → 07:02:00 → Saída: 07:02
  - Entrada → 13:45:00 → Saída: 13:45
  - Entrada → 02:52:00 → Saída: 02:52

34. Inspeção se há valores com final ":00" nas colunas HLA

- Verificar se todas as linhas com ":00" ao final do valor nas colunas HLA foram corrigidas

35. Exclusão de letras após números

- Objetivo: remover tudo após os dois pontos (incluindo os dois pontos) e manter apenas os números antes dele.
- Nas colunas HLA, aplicar correção nos valores que estiverem no formato de números seguidos de dois pontos e letras.
- Exemplos:
  - "04:GEFX" → "04"
  - "08:ANJMN" → "08"

        - "12:XYZ" → "12"
    - Existem situações em que o formato segue a nomenclatura correta do HLA, que pode conter múltiplos blocos de números separados por : e uma letra no final. Nesses casos, a letra não deve ser excluída.
    - Exemplos (devem ser mantidos sem alteração):
        - "02:101:01:02N" → permanece "02:101:01:02N"
        - "08:05:14Q" → permanece "08:05:14Q"
    - **Regras de preservação:**
        - Se o valor for apenas um número, deve ser mantido.
            - Exemplo: "15" → "15"
        - Se o valor tiver apenas números separados por :, sem letras, deve ser mantido.
            - Exemplo: "07:02" → "07:02"
        - Se o valor tiver blocos numéricos separados por : e somente uma letra ao final, deve ser mantido.
            - Exemplo: “02:10:01:02N” -> “02:10:01:02N”

36. Inspeção se há valores com letras após números seguidos de dois pontos

- Verificar se todas as linhas com letras após números seguidos de dois pontos nas colunas HLA foram corrigidas

37. Inspecionar quantas duplicatas existem no banco

- Verificar se existem duplicatas no banco, observando pelo código do paciente, e quantas são

38. Mesclagem das duplicatas

- Chave de identificação: Código do paciente (coluna usada como referência para identificar duplicatas)
- Duplicatas: todos os códigos do paciente repetidos, independentemente da quantidade de vezes que foram repetidos
- **Ações:**

- ❖ Verificar se existem duplicatas com base no Código do paciente (mesmo código aparecendo mais de uma vez)
- ❖ Comparar os campos básicos nas duplicatas: Data de nascimento, Data da coleta, Sexo e Cidade
- ❖ Se houver qualquer divergência nesses 4 campos → excluir todas as duplicatas correspondentes.
- ❖ Se os campos forem exatamente iguais → prosseguir para mesclar as linhas

- Regras de mesclagem para colunas HLA:
  - ❖ Quando existirem múltiplas entradas HLA diferentes entre duplicatas válidas (com dados básicos idênticos), aplicar as seguintes regras para cada coluna HLA:
    - ➢ Mais blocos de “:” vence.
      Ex: 14:02:01 > 14:02
    - ➢ Empate → quem termina com letra vence.
      Ex: 14:02:01L > 14:02:01
      Se ainda empatar → não escolher → reportar o conflito
    - ➢ Exemplo: "14:02:01L" -> "14:02:01" > "14:02" > "14"
    - ➢ Se houver " " (célula vazia) e valor preenchido → manter o valor preenchido
- Resultado esperado após mesclagem:
  - ❖ Cada Código do paciente será representado por uma única linha, as demais linhas do mesmo paciente devem ser excluídas
  - ❖ As colunas HLA terão o melhor valor possível selecionado
  - ❖ Duplicatas com inconsistência nos campos básicos (nascimento, coleta, sexo, cidade) serão completamente removidas

39. Inspecionar se há duplicatas no banco

- Verificar se todas as duplicatas foram mescladas.

40. Exportação final com formatação protegida para Excel (.xlsx)

- Objetivo: Exportar o banco de dados final já limpo, padronizado e pronto para análise, protegendo as colunas HLA contra conversões indesejadas (como 01:01 virar 01:01:00 no Excel).
- **Etapas:**
  - ❖ Após executar todas as etapas de limpeza, padronização e tratamento dos dados no Python prepare o DataFrame final (por exemplo: df_final).
  - ❖ Use a biblioteca openpyxl para criar um arquivo .xlsx.
  - ❖ Salve o arquivo como .xlsx (ex: "banco_hla_tratado.xlsx"), garantindo compatibilidade com Excel e segurança total contra conversões.